



Argentina  
programa  
4.0



Universidad  
Nacional  
de San Martín

# Módulo 3

## Aprendizaje Automático



Argentina  
programa  
4.0



Universidad  
Nacional  
de San Martín

# Módulo 3

# Aprendizaje Automático

Semana 9.  
Autoencoders Variacionales  
Redes Antagónicas Generativas

# Contenidos del módulo


## ML Clásico

- Árboles de Decisión
- Métodos de Ensemble
  - Bagging / Pasting → Random Forests
  - Boosting
- Support Vector Machines


## Deep Learning

- Redes Neuronales
- Redes Neuronales Convolucionales
- Auto-Encoders / Auto-Encoders Variacionales
- Redes Neuronales Recurrentes (LSTM, otras)
- Extras:
  - Generative Adversarial Networks (GAN)
  - Reinforcement Learning

# Autoencoders



# Autoencoders variacionales



# Autoencoders variacionales

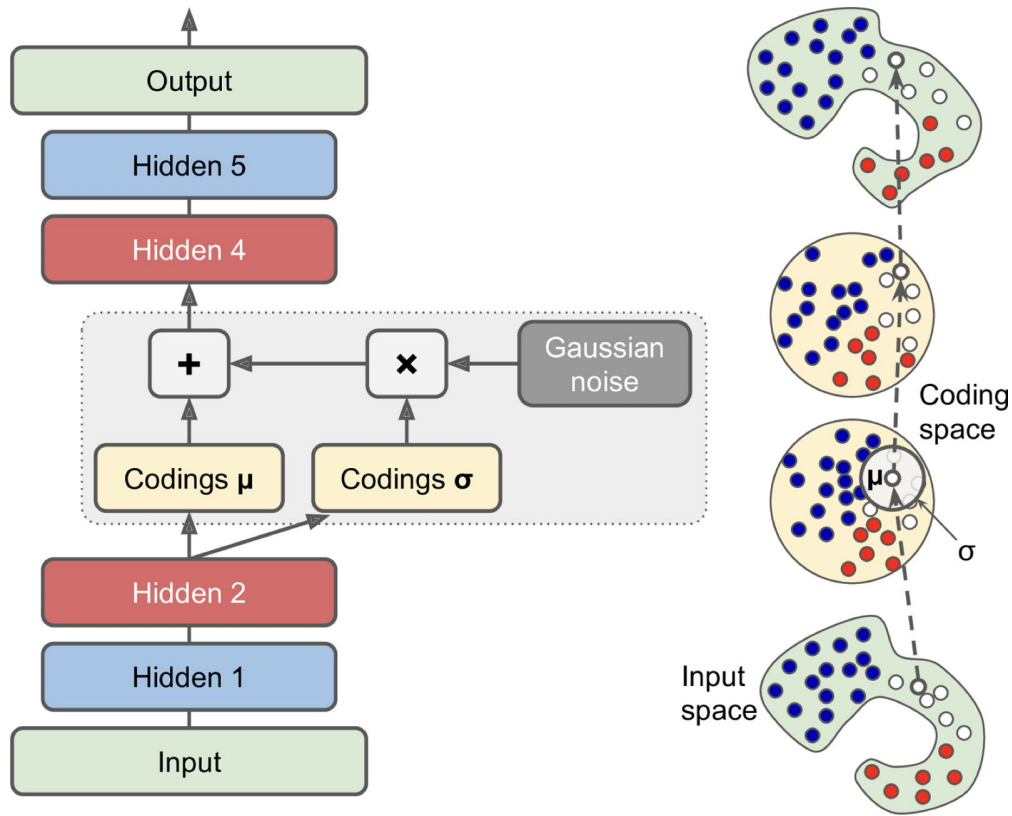



Imagen de Géron

# Autoencoders variacionales

- Modelos probabilísticos. La salida viene determinada parcialmente por el azar.
- Interpolación semántica.
- Son modelos *generativos*. Permiten generar nuevas instancias.



# Notebook

Revisión en

**Notebook\_Semana\_8\_Autoenconders.ipynb**



# Autoencoders variacionales

2013

2023

## Auto-Encoding Variational Bayes


**Diederik P. Kingma**  
Machine Learning Group  
Universiteit van Amsterdam  
dpkingma@gmail.com

**Max Welling**  
Machine Learning Group  
Universiteit van Amsterdam  
welling.max@gmail.com

### Abstract


How can we perform efficient inference and learning in directed probabilistic models, in the presence of continuous latent variables with intractable posterior distributions, and large datasets? We introduce a stochastic variational inference and learning algorithm that scales to large datasets and, under some mild differentiability conditions, even works in the intractable case. Our contributions are two-fold. First, we show that a reparameterization of the variational lower bound yields a lower bound estimator that can be straightforwardly optimized using standard stochastic gradient methods. Second, we show that for i.i.d. datasets with continuous latent variables per datapoint, posterior inference can be made especially efficient by fitting an approximate inference model (also called a recognition model) to the intractable posterior using the proposed lower bound estimator. Theoretical advantages are reflected in experimental results.

McKinsey  
Digital



**The economic potential of generative AI:  
The next productivity frontier**

June 14, 2023 | Report



# Redes Generativas Antagónicas

# GANs - Ideas básicas

- Ideadas por I. Goodfellow et al. (2014).
- Se inspiran en el espacio latente de los autocodificadores variacionales
- Los GAN se componen de dos partes:
  - El modelo generativo (G)
  - El modelo discriminativo (D)
- Ambos modelos compiten entre sí.
  - El modelo D estima la probabilidad de que una muestra proceda del conjunto de entrenamiento y no de G.
  - La estrategia de entrenamiento del modelo G consiste en maximizar la probabilidad de que D cometa un error.

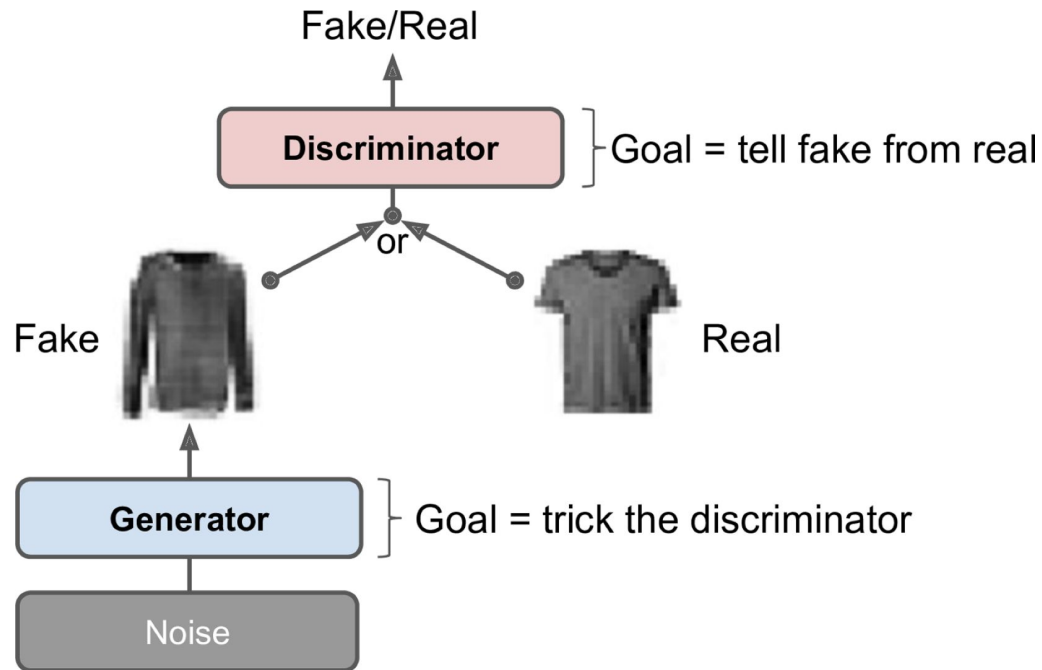


Imagen de Géron

# GANs - Estrategia de entrenamiento

Para entrenar a estos antagonistas, cada paso se divide en dos fases:

1. Entrenar el **discriminador** con un conjunto de imágenes reales y falsas, con etiquetas 1 y 0, respectivamente. Los pesos del **generador** se mantienen **fijos**.
2. Entrenar el **generador**. Se genera un nuevo conjunto de imágenes falsas y se pasa al discriminador con la etiqueta 1 para todas. Los pesos del **discriminador** se mantienen **fijos**.

**Nota:** el generador nunca entrena con imágenes reales; solo intenta vencer al discriminador.

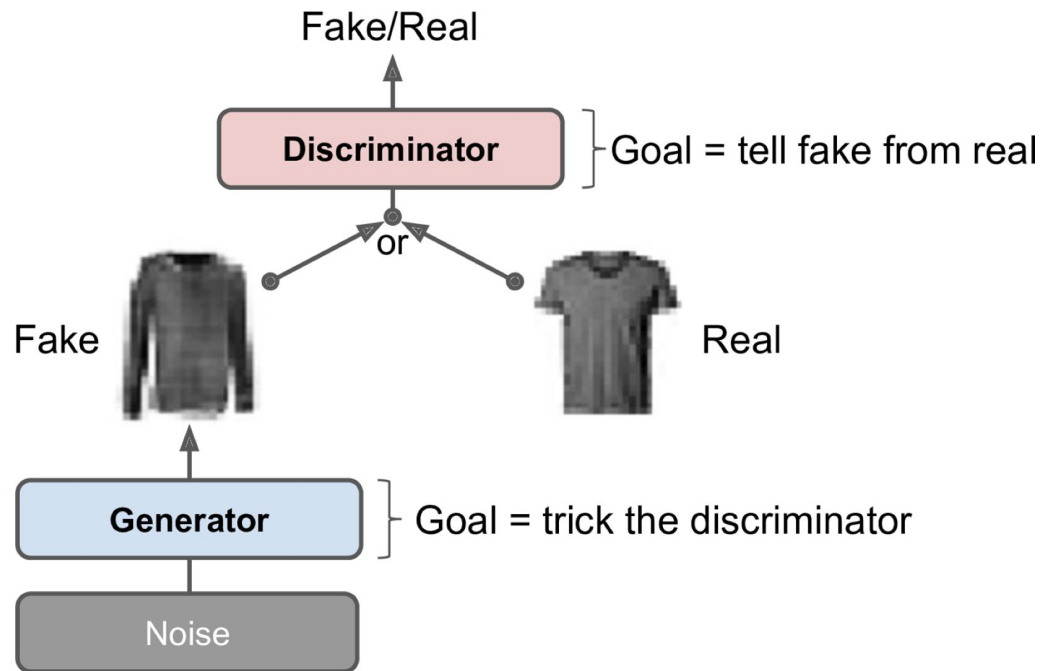


Imagen de Géron

# GANs - Equilibrio de Nash

En su artículo I. Goodfellow et al. (2014) muestran que:

- las GANs corresponde a un juego de suma cero entre G y D.
- el único equilibrio de Nash en este caso (es decir, la situación en la que ninguno de los jugadores prefiere cambiar su estrategia) es:
  - G recupera la distribución de los datos de entrenamiento.
  - D establece 1/2 en todas partes.

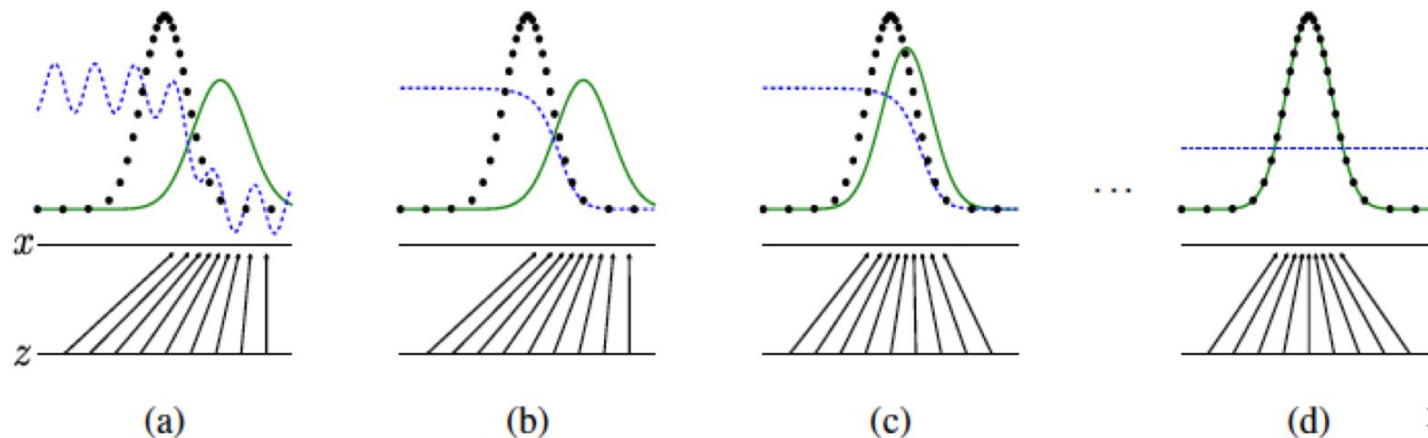


Image from Goodfellow+2014

# GANs - Problemas de entrenamiento

**Mode collapse.** O la pérdida de diversidad.

El generador se vuelve muy bueno produciendo un tipo de datos (zapatos, por ejemplo). Hasta que el discriminador se pone al día, y G cambia a un nuevo conjunto de objetos y olvida lo que sabe sobre los zapatos.

**Oscilaciones e inestabilidades** en los pesos de la red.

## Soluciones

- funciones de costes específicas.
- *Experience replay*. Conservar las imágenes antiguas de G en lugar de utilizar un lote completamente nuevo para entrenar a D.
- *Mini-batch discrimination*. Lotes penalizados baja diversidad.

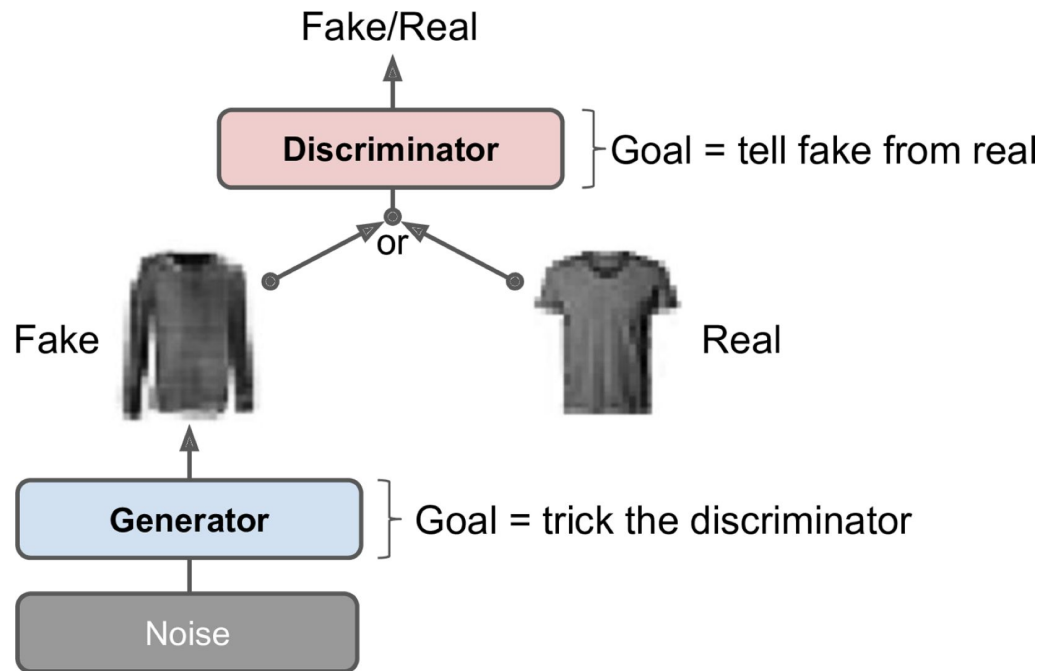


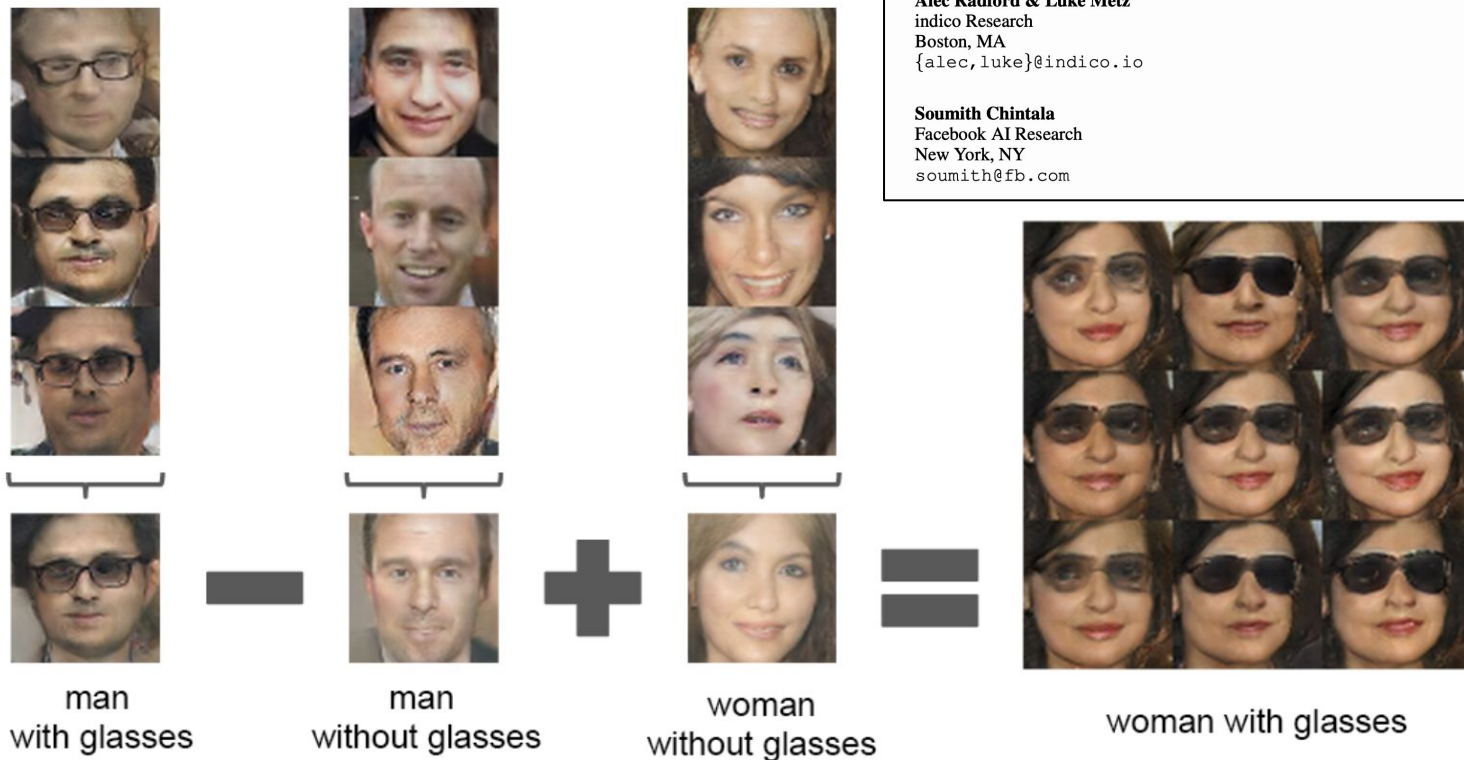
Imagen de Géron

# Deep Convolutional GANs

## UNSUPERVISED REPRESENTATION LEARNING WITH DEEP CONVOLUTIONAL GENERATIVE ADVERSARIAL NETWORKS

**Alec Radford & Luke Metz**  
indico Research  
Boston, MA  
{alec,luke}@indico.io

**Soumith Chintala**  
Facebook AI Research  
New York, NY  
soumith@fb.com



# Notebook

Vamos al notebook!


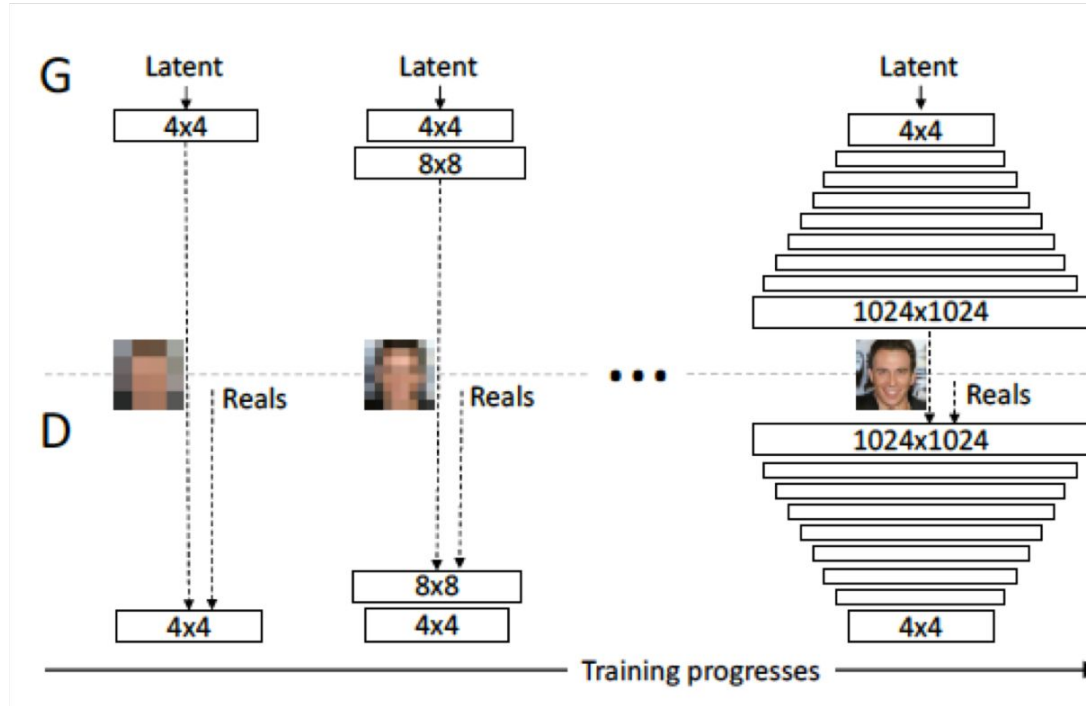
**Notebook\_Semana\_9\_GAN.ipynb**





# Deep Convolutional GANs

Progressive growing of GANs (Karras et al. 2018).



# Deep Convolutional GANs



# StyleGANs

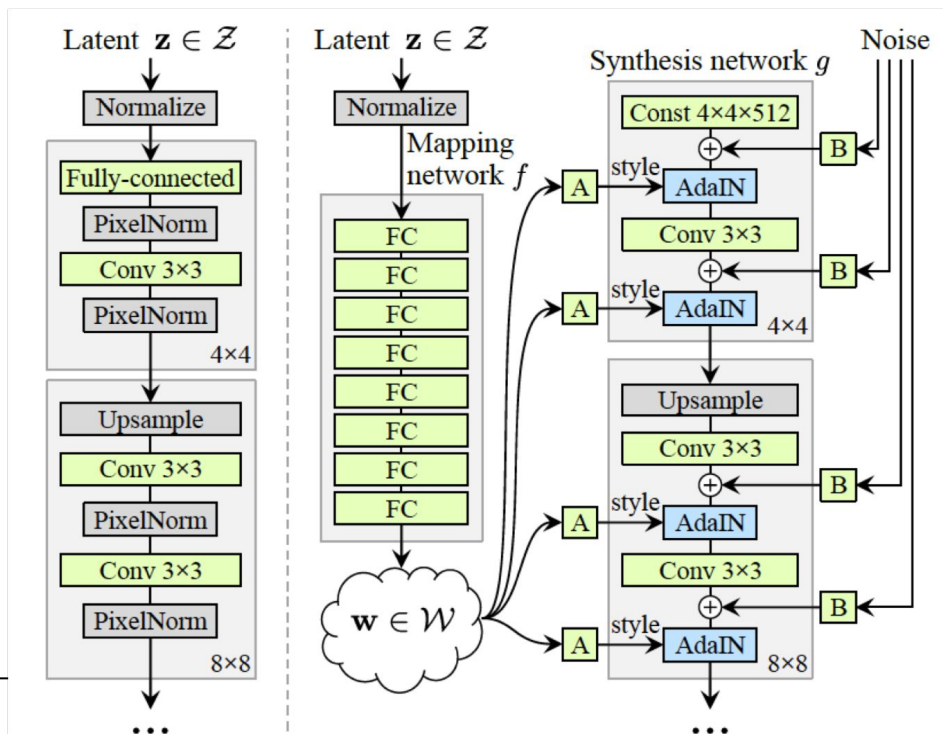
StyleGANs (Karras et al. 2018).

## A Style-Based Generator Architecture for Generative Adversarial Networks

A: styles

B: noise added to the output of convolutional layers

style mixing



# Transferencia de estilos

StyleGANS (Karras et al. 2018).


## A Style-Based Generator Architecture for Generative Adversarial Networks



# Transferencia de estilos

StyleGANs (Karras et al. 2018).

## A Style-Based Generator Architecture for Generative Adversarial Networks





# Transferencia de estilos

StyleGANS (Karras et al. 2018).

**A Style-Based Generator Architecture for Generative Adversarial Networks**

<https://thispersondoesnotexist.com/>

